面向专家微内核的 MLIR 编译与执行

将调用条件贯穿调度生成、代码变换与运行验证

约束驱动的调度生成

A 调用条件建模

库源码 → Contract / Profile

ISA · 布局 · 边界 · ABI

B 候选空间生成

任务信息 + Contract → 检查与去重

direct / adapt / fallback / reject

BaCO 搜索器

选择候选 token

以执行耗时为目标

验证与反馈

D 验证与成本评估

数值 · IR / 符号 · 运行路径

完整库对照 · 编译与调优成本

Transform IR bufferize → packing → call

候选 → 调度实例

运行证据

程序编译与执行

01

Tensor matmul

```
%O = linalg.matmul
  ins(%A, %B : ...)
  outs(%C : ...)
```

C ← C + A × B

02

缓冲区化

tensor → memref

linalg.matmul

显式内存语义

MLIR bufferization

03

C 微内核接入

SCF 分块循环

A/B packing · 尾块处理

Transform op 绑定调用

func.call @BLIS_wrapper

04

标准 lowering

SCF / MemRef / Arith

→ LLVM dialect

→ LLVM IR (.ll)

mlir-translate

05

编译与链接

LLVM IR + driver

+ ABI adapter [C]

+ libblis.a

Clang → 可执行文件

06

CPU 执行

生成代码 → adapter

→ BLIS 6×16 内核

输出 C · 执行耗时

微内核复用 BLIS

Fallback：通用 tiling / 可选 vectorization

tensor 调度 → bufferization

实现路径：x86 · FP32 · BLIS 6×16

本文工作　已有工具与库　---- 调度控制 / 测量反馈　A / B / C / D 对应论文研究与实现