表 4.

学号： 2024214293

西 北 工 业 大 学

非全日制专业学位硕士研究生论文中期报告

学　　院　软件学院

专业或领域　软件工程

姓　　名　冀鲁群

所 在 单 位　待填写

填 表 日 期　2026 年 7 月 9 日

研 究 生 院

姓　名	冀鲁群	学 号	2024214293	第一指导教师	待填写

论文题目	面向 MLIR Transform Dialect 的 Kernel-aware GEMM 调度搜索空间生成方法	第二指导教师	待填写
工程领域	软件工程	论文开题时间	待填写
论文形式	□ 工业设计 ☑ 研究论文	中期报告时间	**2026.07.09**

论文（报告）开题以来情况报告：（包括论文的进度、存在的问题、解决问题的措施）

一、开题以来研究进度

开题后，本课题先把问题收窄到一个可操作的方向：高性能 GEMM 库里的哪些实现事实，可以整理成 MLIR Transform Dialect 调度搜索空间中的约束。研究目标没有放在重写 BLIS、OpenBLAS 或 libxsmm，也没有放在重新设计调优算法。目前主要工作是读高性能库代码，梳理 microkernel、cache blocking、packing、vectorization 和 ISA 相关事实，判断哪些内容以后可以进入搜索空间生成流程。

资料学习主要围绕 Level-3 BLAS、GotoBLAS/BLIS、OpenBLAS、libxsmm、MLIR Transform Dialect、Ansor、MetaSchedule 和 BaCO 展开。通过这部分学习，已经明确 GEMM 的性能不是由单个 tile size 决定的，而是和 microkernel 形状、缓存分块、packing 布局、向量化方式、边界处理以及目标指令集一起相关。这一点也决定了后面不能只摘几个参数，需要把参数所在的库实现上下文一起记录下来。

目前研究仍处在专家事实提取阶段。现阶段以 BLIS 的 Haswell 平台配置作为第一个重点对象，正在整理其中与 GEMM 有关的 microkernel 注册、packm kernel、row preference、MR/NR/MC/KC/NC blocking 参数和 gemmsup 路径等信息。例如，BLIS Haswell 配置文件中可以看到不同数据类型对应的 GEMM microkernel、packing kernel 和 blocking 参数设置。这些内容已经可以作为专家事实表的候选字段，但还需要继续核对其适用条件和调用路径，暂时还没有完成规则化建模。

为了避免后面只得到一堆零散参数，目前已经开始设计专家事实记录字段。初步字段包括事实来源、库名称、平台名称、数据类型、kernel 名称、microkernel 形状、blocking 参数、packing 相关信息、row/column preference、适用条件和证据位置。这样记录的好处是每个参数都能回到源代码位置，也能保留它和数据类型、平台配置之间的关系，后面再考虑是否进入 Microkernel Contract 或搜索空间约束。

除专家事实提取外，已经跑通原始 Transform Dialect 与 BaCO 结合的 GEMM 调优流程，并复现了 Transform Dialect 论文实验 4.5 的相关流程。这个流程已经能够从 Transform Dialect 暴露 GEMM 调度参数，由 BaCO 采样候选配置，再完成编译、运行和测量反馈。这里跑通的是原始调优流程，可以作为后续对比用的基线；BLIS/OpenBLAS/libxsmm 中提取的专家事实还没有接入该流程。

二、阶段性进展

第一，研究范围已经稳定下来。课题从比较宽泛的 GEMM 自动优化问题，收敛到“专家事实驱动的 kernel-aware 搜索空间生成”问题。这样处理后，研究重点更清楚：前端使用 Transform Dialect 表达调度，调优部分沿用 BaCO，主要新增工作放在专家事实提取和搜索空间约束上。

第二，已经初步梳理出需要重点记录的 GEMM 优化事实。包括 microkernel shape、MR/NR、MC/KC/NC、packing layout、row/column preference、数据类型、目标 ISA、tail 处理以及 library/microkernel 替换条件等。后面会围绕这些字段继续整理 BLIS、OpenBLAS 和 libxsmm 的实现信息。

第三，BLIS Haswell 配置的分析已经开始。当前已经定位到 GEMM microkernel、packing kernel、gemmsup kernel、row preference 和 blocking 参数等信息来源。下一步还要继续核对这些信息在不同数据类型下的差异，以及它们和实际调用路径之间的关系。这个阶段的产出应当是可追溯的专家事实表，而不是最终实验结论。

第四，原始 Transform Dialect + BaCO 的 GEMM 调优流程已经跑通，并完成了 Transform Dialect 论文实验 4.5 的基本复现。这个结果说明后面已有一个可以复用的基线流程。接下来可以在这个流程上逐步加入专家事实约束，再比较 generic tuning space 和 kernel-aware tuning space 的差别。

第五，后续技术路线已经初步排好。先完成 BLIS/OpenBLAS/libxsmm 中专家事实的抽取和字段统一，再设计 Microkernel Contract 的核心字段；随后研究这些字段如何约束 Transform Dialect 中的 tiling、packing、vectorization 和 library replacement 参数；最后基于已经跑通的原始调优流程开展小规模对比验证。

三、存在的问题
第一，专家事实在高性能库中分布比较散。以 **BLIS** 为例，**microkernel**、**packing kernel**、**blocking** 参数和偏好设置并不在一个统一表里，而是和平台配置、数据类型、宏定义以及运行时上下文初始化过程放在一起。单独抄出一个参数容易漏掉它的条件，所以还需要反复对照源代码。
第二，不同库的写法差异比较大。**BLIS** 的平台配置相对模块化，**OpenBLAS** 和 **libxsmm** 在 **kernel** 组织、参数来源和调用路径上又是另一套风格。后面如果要做统一的专家事实表，必须先解决字段对齐问题，不能把某个库的实现细节直接当成通用 **GEMM** 规律。
第三，事实和规则之间的边界还需要继续判断。现在可以提取到 **MR/NR**、**MC/KC/NC**、**kernel** 名称、**packing kernel** 等事实，但这些事实不能直接等同于调度规则。哪些是必须满足的接口约束，哪些只能作为搜索空间的经验范围，哪些只是某个平台的实现细节，还需要结合更多代码和后续实验再定。
第四，虽然原始 **Transform Dialect + BaCO** 的 **GEMM** 调优流程已经跑通，但它目前只是基线复现，还没有接入专家事实约束。因此，专家规则是否能够缩小搜索空间、提高候选有效率、改善收敛效率或替换成功率，现在还不能下结论。这部分需要等专家事实表和规则设计稳定后再做实验。
四、解决措施与下一步计划
针对专家事实分散的问题，下一步继续从 **BLIS Haswell** 配置入手，按数据类型、**microkernel**、**blocking** 参数、**packing kernel**、偏好设置和证据位置来建立记录表。每条记录都保留源代码位置和适用条件，避免后面脱离上下文使用参数。

针对不同库字段不一致的问题，后面选取 OpenBLAS 的典型 GEMM kernel 路径和 libxsmm 的小矩阵 GEMM 路径做对照。比较时先不追求覆盖所有平台，而是先把字段含义和证据位置理清楚，再逐步扩展到更多数据类型和架构。
针对事实到规则的转化问题，后续先把专家事实分层处理。数据类型、microkernel shape、packing layout 和 alignment 这类内容优先作为接口约束；cache blocking 范围和 row/column preference 这类内容先作为搜索空间的经验范围；暂时无法确认通用性的库内细节先保留在事实表中，不急于写入规则库。这样可以逐步形成 Microkernel Contract 和调度规则的初步设计。
后续工作按四步推进：先完成 BLIS Haswell 专家事实表；再补充 OpenBLAS 和 libxsmm 的对照事实；之后设计 Microkernel Contract 字段和 Transform Dialect 参数约束映射，并接入已经跑通的 Transform Dialect + BaCO 调优流程；最后在小规模 GEMM case 上比较原始搜索空间和专家事实约束空间。实验数据以实际运行为准，不使用估计值替代。

第二导师意见	综合评价意见： 指导教师（签字） 年　月　日

备 注	