表4.

学号：2024214293

西 北 工 业 大 学

非全日制专业学位硕士研究生论文中期报告

学　　院	软件学院
专业或领域	软件工程
姓　　名	冀鲁群
所 在 单 位	待填写
填 表 日 期	2026年7月9日

研 究 生 院

姓　名	冀鲁群	学 号	2024214293	第一指导教师	待填写
论文题目	面向 MLIR Transform Dialect 的 Kernel-aware GEMM 调度搜索空间生成方法			第二指导教师	待填写
工程领域	软件工程			论文开题时间	待填写
论文形式	□ 工业设计　☑ 研究论文			中期报告时间	2026.07.09

论文（报告）开题以来情况报告：（包括论文的进度、存在的问题、解决问题的措施）

一、开题以来论文进度

开题以来，论文工作围绕“高性能 GEMM 库专家知识如何转化为 MLIR Transform Dialect 可搜索调度空间”这一主线推进。当前已完成论文总体框架设计，形成了绪论、相关技术背景、面向 GEMM 的专家规则抽象、Kernel-aware 调度搜索空间生成方法、系统实现与实验分析、总结与展望六章结构。论文的研究边界也已进一步明确：本文不以重新实现 BLIS、OpenBLAS 或 libxsmm 等成熟 GEMM 库为目标，也不重新设计新的搜索算法，而是重点研究如何将高性能库中的 microkernel、cache blocking、packing、vectorization 等专家事实抽象为可检查、可组合、可调优的搜索空间约束。

文献调研方面，已围绕 Level-3 BLAS、GotoBLAS/BLIS/OpenBLAS/libxsmm 高性能 GEMM 实现、MLIR 与 Transform Dialect、Ansor/MetaSchedule/BaCO 等自动调优系统开展整理。现有调研表明，高性能库能够提供经过实践验证的硬件优化知识，Transform Dialect 能够显式表达 tiling、packing、vectorization 和 library replacement 等调度动作，BaCO 等调优器能够在给定参数空间内执行搜索；但三者之间仍缺少从库内专家事实到调度搜索空间的统一映射机制。这一判断已写入论文绪论和相关技术背景章节。

方法研究方面，已完成面向 GEMM 的专家规则抽象。论文从高性能库实现中提炼了 microkernel shape、MR/NR、MC/KC/NC、packing layout、alignment、数据类型、目标 ISA、tail policy 和调用约定等专家事实，并将其表示为包含适用条件、硬约束、软先验、参数范围、优先级、退化策略和证据来源的结构化规则。进一步地，论文建立了 Microkernel Contract 模型，用于描述候选调度与底层 microkernel 或 library path 在 shape、dtype、ISA、layout、memory、tail 和 call 等方面的兼容条件，从而区分“Transform Dialect 变换合法”和“底层 kernel 可接管”两个不同层次。

搜索空间生成方面，已完成 Kernel-aware 调度搜索空间生成方法的章节撰写。该方法以 GEMM payload IR、专家规则库、Microkernel Contract registry 和目标平台信息为输入，经过专家事实筛选、规则实例化、兼容性检查、Transform Dialect 模板映射和参数空间导出等步骤，生成可交由 BaCO 等调优器搜索的 tuning parameter space。当前方法已经覆盖 cache blocking、packing 与数据布局、vectorization 与 ISA 相关规则、unroll、parallelization 以及 library/microkernel replacement 等调度决策，并保留候选的规则来源、兼容性状态和退化路径。

系统实现与实验设计方面，已完成第五章的实现框架和实验评价方案。系统被划分为专家规则模块、Contract Registry、搜索空间生成器、兼容性检查器、调优驱动模块和测量记录模块。实验部分已明确不编造尚未完成的性能数据，并设计了真实实验应记录的字段，包括实验环境、搜索空间规模、有效候选比例、microkernel/library 替换成功率、best-so-far 收敛曲线、相同搜索预算下的性能表现以及 MR/NR、cache blocking、packing、vectorization、compatibility checker 等规则的消融影响。

同时，已建立实验日志和 CSV 数据模板，为后续补充真实测量结果提供结构化基础。

二、阶段性成果

目前论文已形成较完整的正文初稿，六个主体章节均已具备基本内容。其中，第一章完成研究背景、国内外研究现状、问题挑战、研究内容与贡献、论文组织结构；第二章完成 GEMM 计算与高性能优化、BLIS/OpenBLAS/libxsmm 高性能库、MLIR 与 Transform Dialect、自动调优与 BaCO 以及现有方法局限性分析；第三章完成专家事实、Microkernel Contract、Cache Blocking、Packing、Vectorization 与 ISA 相关规则以及专家规则表示方法；第四章完成 Kernel-aware 搜索空间生成总体框架、专家事实提取器、兼容性检查器、规则到 Transform Dialect 的映射、Tuning Parameter Space 生成以及与 BaCO 的集成；第五章完成系统实现框架和实验分析模板；第六章完成总结与展望。

除正文撰写外，已整理参考文献条目并在章节中插入与 BLAS、BLIS、OpenBLAS、libxsmm、MLIR、Transform Dialect、Ansor、MetaSchedule、BaCO 等相关的引用。论文当前已经能够通过 XeLaTeX 编译生成 PDF，说明章节组织、基本 LaTeX 结构、参考文献和表格公式已具备进一步修改的基础。

三、存在的问题

第一，专家事实的抽取仍存在工程复杂性。BLIS、OpenBLAS 和 libxsmm 等库中的高性能实现与具体平台、版本和数据类型相关，部分参数分散在配置文件、宏定义、手写 kernel 和构建逻辑中。若仅依赖人工整理，后续规则库维护成本较高，也容易遗漏特殊 shape、tail 处理或平台分派条件。

第二，Microkernel Contract 与 Transform Dialect 模板之间的映射仍需要进一步细化。库级规则往往包含多级 blocking、packing、loop ordering、vectorization、unroll 和 replacement 的组合，而 Transform Dialect 中的 handle、parameter、变换顺序和失败传播机制要求较严格。如果映射过于粗略，候选可能只能满足语法合法性，不能保证后续 lowering 和 library/microkernel 替换成功。

第三，实验数据仍需补充。当前第五章已经形成实验框架、评价指标和数据记录模板，但尚未写入真实运行时间、GFLOPS、收敛曲线、替换成功率和消融实验结果。由于这些指标必须来自实际编译和测量，不能用估计值替代，因此实验结论部分还需要在后续实现和测试完成后进一步完善。

第四，论文表述还需要继续压缩和统一。当前各章节已经形成初稿，但部分术语、变量符号、规则名称和章节之间的衔接仍需进一步校对，尤其是 kernel-aware、Microkernel Contract、expert rule、tuning parameter space 等中英文术语需要保持全文一致。

四、解决措施与下一步计划

针对专家事实抽取问题，后续将优先选择 BLIS haswell 配置、OpenBLAS 典型 GEMM kernel 路径和 libxsmm 小矩阵场景作为受控范围，先保证规则来源可追溯、字段含义明确，再逐步扩展到更多平台。规则库中将继续保留证据来源、适用条件和退化策略，避免把特定平台参数误写成普适结论。

针对映射复杂性问题，后续将把候选生成流程拆分为可验证的小步骤：先检查 GEMM 语义和数据类型，再检查 MR/NR、layout、alignment、tail policy 等 contract 字段，随后生成 Transform Dialect 模板和参数槽位，最后记录 direct、adapt、fallback 或 reject 判定。这样可以在候选失败时定位原因，并为实验中的替换成功率和失败原因统计提供依据。

针对实验数据不足问题，后续将按照第五章已经建立的数据模板补充真实实验。实验将记录硬件环境、MLIR/LLVM 版本、BLIS/OpenBLAS/libxsmm 版本、编译选

项、搜索预算、随机种子、候选编译状态、正确性检查结果、运行时间分布和失败原因。性能结果将采用重复测量后的统计值呈现，并在论文中明确区分实测结果、实验设置和方法分析，避免使用未验证数据。 后续进度安排如下：第一阶段完善系统实现与规则库字段，保证候选空间能够稳定生成；第二阶段完成基线空间与 kernel-aware 空间的对比实验，补充搜索空间质量、收敛效率和替换成功率数据；第三阶段完成消融实验和图表整理；第四阶段统一修改论文术语、公式、图表编号和参考文献格式；第五阶段根据导师意见完成终稿修改和答辩准备。

第二导师意见	综合评价意见： 指导教师（签字）： 年　月　日
备注	